

Simultaneous Localisation and Mapping (SLAM)

Part I The Essential Algorithms

Mateusz Jaworski (155234)

Michał Kaczmarek (155043)

Na podstawie artykułu autorstwa:

Hugh Durrant-Whyte, Fellow, IEEE, and Tim Bailey

Sztuczna inteligencja w robotyce

mgr inż. Joanna Piasek-Skupna

14 czerwca 2026

Część I: Teoria

- **Probabilistyczne ujęcie problemu SLAM** – sformułowanie matematyczne.
- **Rozszerzony Filtr Kalmana (EKF-SLAM)** – klasyczne podejście analityczne, wady i ograniczenia skalowalności.
- **Algorytm FastSLAM** – faktoryzacja Rao-Blackwellization oraz zastosowanie filtrów cząsteczkowych.

Część II: Implementacja Praktyczna

- **Środowisko testowe:** Rakieta sondażowa „MORA I” (PUT Rocketlab).
- **Model fuzji danych:** Integracja pomiarów telemetrycznych (TDoA + rurka Pitota + IMU).
- **Analiza odporności systemu:** Zachowanie estymatorów w warunkach krytycznej awarii stacji naziemnych.
- **Weryfikacja metryk:** Porównanie błędu euklidesowego pozycji 3D.

Dlaczego podejście probabilistyczne?

W rzeczywistych warunkach operacyjnych czujniki są zaszumione, a układy wykonawcze generują poślizgi. Zgodnie z analizowanym artykułem, robot nie szuka pojedynczej, deterministycznej pozycji, lecz estymuje rozkład prawdopodobieństwa swojego stanu w otoczeniu.

Istota problemu według autorów (Łączny rozkład gęstości):

$$p(x_{1:t}, m \mid z_{1:t}, u_{1:t})$$

Celem jest wyznaczenie łącznego prawdopodobieństwa całej trajektorii robota ($x_{1:t}$) oraz geometrii mapy (m), na podstawie historii pomiarów ($z_{1:t}$) i komend sterujących ($u_{1:t}$).

Wkład naukowy artykułu:

Autorzy udowadniają, że powyższy rozkład posiada strukturę, która pozwala na jawne rozwiązanie problemu SLAM. Artykuł systematyzuje i porównuje dwa podejścia do tego problemu:

- **EKF-SLAM** – rozwiązujące problem analitycznie poprzez linearyzację metodą Taylora w ramach jednego wektora stanu.
- **FastSLAM** – rozwiązujące problem poprzez faktoryzację (Rao-Blackwellization) na filtr cząsteczkowy (trajektoria) i niezależne filtry Kalmana (landmarki).

Historycznie pierwsze i najbardziej znane rozwiązanie problemu probabilistycznego SLAM.

Reprezentacja stanu:


Wektor stanu systemu składa się z aktualnego położenia robota, do którego dołączone są współrzędne wszystkich zmapowanych landmarków.

Zasada działania:


Algorytm operuje w nieprzerwanej pętli składającej się z dwóch kroków:

- **Predykcja** – szacowanie nowego stanu robota na podstawie modelu ruchu (np. z odometrii), wykorzystujące Jakobiany do linearyzacji.
- **Aktualizacja** – korekta nagromadzonych błędów za pomocą pomiarów z zewnętrznych sensorów.

Demonstracja działania EKF-SLAM na przykładzie UGV



- Skalowalność $O(N^2)$ - koszt obliczeniowy oraz wymagana pamięć rosną kwadratowo z ilością wykorzystanych landmarków
- Nieliniowość - EKF-SLAM działa na zlinearyzowanych modelach. W przypadku silnie nieliniowych ruchów algorytm może generować błędy aproksymacji.
- Błędne rozpoznanie - błędne przypisanie pomiaru do niewłaściwego landmarku może nieodwracalnie zniszczyć strukturę macierzy kowariancji i bezpowrotnie zdeformować całą mapę.



Rysunek 1: Problem zamykania pętli (loop closing) wynikający z błędnego dopasowania landmarków. Źródło: Elasmr, S. R. A. G., 2012, *Information-Theoretic Environment Modeling for Mobile Robot Localization*.

Rozwiązanie problemu probabilistycznego SLAM, oparte na architekturze filtrów cząsteczkowych.

Koncepcja:

Rozkład prawdopodobieństwa pozycji robota nie jest aproksymowany pojedynczą funkcją Gaussa. Jest on reprezentowany dyskretnie przez **chmurę N niezależnych cząsteczek** (hipotez geometrycznych).

Pojedyncza cząsteczka (Rao-Blackwellization):

Zamiast jednej dużej macierzy kowariancji, każda cząsteczka $[k]$ oblicza:

- Swoją własną, dokładną współrzędną pozycji $[x, y, \theta]^{[k]}$.
- Zbiór M **niezależnych, miniaturowych filtrów EKF** (każdy o wymiarze zaledwie 2×2) – po jednym dla każdego zmapowanego landmarku.

Algorytm realizuje proces estymacji sekwencyjnie w trzech głównych fazach:

❶ **Predykcja (Generowanie hipotez):**

Każda cząsteczka niezależnie aktualizuje swoją pozycję, losując nową współrzędną na podstawie modelu ruchu zaszumionego losową wartością z macierzy Q (np. odometria). Powstaje chmura alternatywnych tras.


❷ **Aktualizacja i Ważenie (Ocena rzeczywistości):**

Gdy robot odbiera pomiary z sensorów (z_t), każda cząsteczka aktualizuje pozycje zaobserwowanych w danym momencie landmarków w swoich małych EKF'ów. Następnie oblicza swoją wagę (prawdopodobieństwo): im bliżej jej własnych landmarków leży pomiar, tym większą wagę otrzymuje.

❸ **Selekcja (Resampling):**

Cząsteczki o wysokich wagach (które najlepiej odzwierciedliły rzeczywistość) są powielane. Cząsteczki o niskich wagach są usuwane.

Demonstracja działania FastSLAM na przykładzie UGV



Zalety FastSLAM

- **Wydajność:** Złożoność obliczeniowa $O(M \log N)$ zamiast $O(N^2)$.
- **Wielomodalność:** Dzięki cząsteczkom algorytm śledzi wiele hipotez trajektorii jednocześnie.
- **Asocjacja danych:** Dużo większa odporność na błędy rozpoznawania obiektów – błędne cząsteczki są usuwane w procesie resamplingu.

Wady i Wyzwania


- **Degeneracja:** Cząsteczki z czasem tracą różnorodność (wszystkie stają się kopiami jednej), co może prowadzić do utraty spójności mapy.
- **Pamięć:** Konieczność przechowywania pozycji wszystkich landmarków dla każdej cząstki.
- **Strojenie:** Trudniejszy dobór parametrów

FastSLAM rozwiązuje problem skalowalności EKF poprzez wykorzystanie niezależności warunkowej landmarków względem trajektorii (Rao-Blackwellization).

Lokalizacja rakiet sondażowych za pomocą multilateracji (TDoA)




Rakieta PUT Rocketlab "MORA I"
(FAR-OUT 2026)




Multilateracja nadajnika (TDoA) w kole PUT Rocketlab

- **Stacje odbiorcze:** System wykorzystuje sieć czterech stacji odbiorczych TDoA o znanych, trójwymiarowych współrzędnych geograficznych oraz synchronizacji czasu.
- **Estymacja wektora prędkości:** Dane telemetryczne z pokładu rakiety dostarczają orientację przestrzenną (AHRS) oraz prędkość rakiety (airspeed - rurka Pitota). Pozwala to na wyznaczenie składowych prędkości $[V_N, V_E, V_D]$ w układzie odniesienia NED (przy założeniu braku wiatru).
- **Charakterystyka zakłóceń:** Szum pomiarowy odległości z TDoA (R) oraz szum niedoskonałości modelu kinematycznego (Q) są aproksymowane niezależnym, szumem gaussowskim.




Rysunek 2: Trójwymiarowa trajektoria lotu rakiet



Rysunek 3: Wycinek trajektorii w którym nastąpiła awaria stacji

Analiza błędu euklidesowego pozycji 3D



Rysunek 4: Porównanie błędu euklidesowego pozycji: EKF vs uśredniona multilateracja

Filtr EKF redukuje szum pomiarowy i zachowuje ciągłość estymacji (funkcja predykcji) pomimo utraty łączności z częścią stacji naziemnych, podczas gdy klasyczne podejście generuje opóźnienia lub całkowity brak zbieżności.

